

K-means Clustering

O'nel Hounnouvi

1 Modélisation et objectif

Le problème des k-moyennes (*k-means* en anglais) est un problème d'optimisation combinatoire de partitionnement de données. On dispose d'un ensemble de points $\{x_1, \dots, x_n\} \subseteq \mathbb{R}^n$ et d'un entier $k \in \mathbb{R}$ (nombre de clusters). Le problème consiste à trouver une partition de ces points en k groupes $C_1, \dots, C_k$ appelés clusters. Chaque cluster est représenté par un centroïde μ_j , un point qui représente le centre du cluster.

Il s'agit donc de minimiser la variance à l'intérieur de chaque groupe, c'est-à-dire la distance entre les points d'un cluster avec leur centroïde.

$$\min_{C_1, \dots, C_n} \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

2 Dérivation

Deux sous-problèmes se résolvent en fermé:

Centroïde optimal, à affectation fixée

Soit $C_1, \dots, C_k$ une partition fixée de $\{x_1, \dots, x_n\}$. On a la fonction de coût associée:

$$J(\mu_j) = \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

Chaque J_j ne dépend que de μ_j ; on peut donc minimiser terme par terme.

$$\nabla_{\mu_j} J(\mu_j) = \sum_{x_i \in C_j} -2(x_i - \mu_j) = 0$$

$$\sum_{x_i \in C_j} x_i - |C_j| \mu_j = 0$$

$$\mu_j^* = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

Le centroïde optimal est donc la moyenne des points de son cluster.

Affectation optimale à centroides fixés

A $\mu_1, \dots, \mu_k$ fixés, notons $C(i)$ le cluster assigné au point x_i . La fonction de perte s'écrit

$$J(C) = \sum_{i=1}^n \|x_i - \mu_{C(i)}\|^2$$

Elle se décompose en n termes indépendants, un par point: le terme pour x_i ne dépend que de $C(i)$ et jamais de l'affectation des autres points. Minimiser $J(C)$ sur toutes les affectations possibles revient donc à minimiser chaque terme séparément:

$$C^*(i) = \arg \min_{j \in \{1, \dots, k\}} \|x_i - \mu_j\|^2$$

Cela revient à assigner chaque point au centroïde le plus proche, ce dernier étant le représentant du cluster.

Le problème global est intraitable. Trouver le partitionnement optimal est NP-difficile, même pour $k = 2$ en dimension quelconque (Aloise et al., 2009), ou pour $d = 2$ à k quelconque (Mahajan et al., 2009). C'est la raison pour laquelle on utilise une heuristique.

3 Algorithme de Lloyd

L'algorithme de Lloyd exploite directement les deux résultats précédents en alternant les deux étapes : affecter chaque point à son centroïde le plus proche (bloc C , à μ fixé), puis recalculer chaque centroïde comme la moyenne de son cluster (bloc μ , à C fixé). Il s'agit d'un algorithme itératif de type descente par coordonnées par blocs.

1. **Initialisation** : Choisir k centroïdes initiaux $\mu_1^{(0)}, \dots, \mu_k^{(0)}$.

2. **Itération t** :

- *Étape d'affectation* : Assigner chaque point x_i au centroïde le plus proche pour former les clusters $C_1^{(t)}, \dots, C_k^{(t)}$:

$$C^{(t)}(i) = \arg \min_{j \in \{1, \dots, k\}} \|x_i - \mu_j^{(t-1)}\|^2$$

- *Étape de mise à jour* : Recalculer les centroïdes de chaque cluster :

$$\mu_j^{(t)} = \frac{1}{|C_j^{(t)}|} \sum_{x_i \in C_j^{(t)}} x_i$$

3. **Arrêt** : Répéter l'étape 2 jusqu'à convergence, c'est-à-dire lorsque les affectations ne changent plus d'une itération à l'autre (ou que la variation de la fonction objectif J devient inférieure à un seuil défini).

4 Convergence

Chacune des deux étapes est une minimisation *exacte* de son sous-problème, pas une approximation, donc la fonction de coût ne peut que décroître ou stagner à chaque étape. Ça ne garantit pas pour autant l'optimum global. Comme le nombre de partitions possibles des n points en k clusters est fini, l'algorithme converge nécessairement vers un optimum *local*. Toutefois, ce minimum n'est pas garanti d'être global car le problème initial est non-convexe. Cela dépend fortement de l'initialisation des centroïdes $\mu_1^{(0)}, \dots, \mu_k^{(0)}$.