

K-means Clustering

O'nel Hounnouvi

1 Modélisation et objectif

Le problème des k-moyennes (*k-means* en anglais) est un problème d'optimisation combinatoire de partitionnement de données. On dispose d'un ensemble de points $\{x_1, \dots, x_n\} \subseteq \mathbb{R}^n$ et d'un entier $k \in \mathbb{R}$ (nombre de clusters). Le problème consiste à trouver une partition de ces points en k groupes $C_1, \dots, C_k$ appelés clusters, minimisant la variance à l'intérieur de chaque groupe. Plus précisément, il s'agit de minimiser la somme des carrés des distances de chaque point à la moyenne des points de son groupe.

$$\min_{C_1, \dots, C_n} \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2, \quad \mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

Deux sous-problèmes se résolvent en fermé:

Centroïde optimal, à affectation fixée

Soit $C_1, \dots, C_k$ une partition fixée de $\{x_1, \dots, x_n\}$. On a :

$$J(\mu_j) = \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

Chaque J_j ne dépend que de μ_j ; on peut donc minimiser terme par terme.

$$\nabla_{\mu_j} J(\mu_j) = \sum_{x_i \in C_j} -2(x_i - \mu_j) = 0$$

$$\sum_{x_i \in C_j} x_i - |C_j| \mu_j = 0$$

$$\mu_j^* = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

Affectation optimale à centroïdes fixés

A $\mu_1, \dots, \mu_k$ fixés, notons $C(i)$ le cluster assigné au point x_i . La fonction de perte s'écrit

$$J(C) = \sum_{i=1}^n \|x_i - \mu_{C(i)}\|^2$$

Elle se décompose en n termes indépendants, un par point: le terme pour x_i ne dépend que de $C(i)$ et jamais de l'affectation des autres points. Minimiser $J(C)$ sur toutes les affectations possibles revient donc à minimiser chaque terme séparément:

$$C^*(i) = \arg \min_{j \in \{1, \dots, k\}} \|x_i - \mu_j\|^2$$

Cela revient à assigner chaque point au centroïde le plus proche, ce dernier étant le représentant du cluster.

Le problème global est intraitable. Trouver le partitionnement optimal est NP-difficile, même pour $k = 2$ en dimension quelconque (Aloise et al., 2009), ou pour $d = 2$ à k quelconque (Mahajan et al., 2009).

2 Algorithme de Lloyd

L'algorithme de Lloyd exploite directement les deux résultats précédents en alternant l'optimisation sur l'affectation et sur les centroïdes. Il s'agit d'un algorithme itératif de type descente coordonnée.