Random Forests

O'nel Hounnouvi

1 Modélisation

On dispose d'un jeu de données $\mathcal{D} = (X, y)$ avec $X \in \mathbb{R}^{n \times d}$ (n échantillons, d variables), et $y \in \mathbb{R}^n$ en régression ou $y \in \{1, \dots, K\}^n$ en classification.

Une forêt aléatoire est un ensemble de B arbres de décision randomisés $T_1, \dots, T_B$ (construction des arbres détaillée dans le document Decision Tree), entraînés indépendamment les uns des autres, conditionnellement à $\mathcal{D}$.

La prédiction agrège les sorties des arbres : en régression, on en calcule la moyenne, et en classification, on prend la classe majoritaire parmi les prédictions des arbres.

$$f(x) = \frac{1}{B} \sum_{b=1}^{B} T_b(x) \quad \text{(régression)}, \qquad f(x) = \arg\max_k \sum_{b=1}^{B} \mathbb{1}_{\{T_b(x)=k\}} \quad \text{(classification)}$$

L'un des problèmes majeurs des arbres de décision réside dans leur forte variabilité. Souvent, une légère modification des données peut entraîner une série de divisions de l'arbre très différente, rendant l'interprétation des résultats difficile. La cause principale de cette instabilité tient à la nature hiérarchique du processus : l'impact d'une erreur lors de la première division se propage à toutes les divisions qui en découlent.

2 Objectif : Bagging

L'idée fondamentale du bagging consiste à aggréger plusieurs arbres de décision bruités mais approximativement non biaisés, afin de réduire la variance. Pour B arbres de corrélation ρ, de même variance σ^2, et donc de covariance $\mathrm{Cov}(T_i, T_j) = \rho\sigma^2$ pour tout $i \neq j$, la variance de la moyenne est donnée par:

$$\begin{aligned}
Var\left(\frac{1}{B}\sum_{b=1}^{B} T_b\right) &= \frac{1}{B^2} Var\left(\sum_{b=1}^{B} T_b\right) \\
&= \frac{1}{B^2}\left[\sum_{b=1}^{B} Var(T_b) + \sum_{i \neq j} \mathrm{Cov}(T_i, T_j)\right] \\
&= \frac{1}{B^2}\left[B\sigma^2 + B(B-1)\rho\sigma^2\right] \\
&= \frac{\sigma^2}{B} + \frac{B-1}{B}\rho\sigma^2 \\
&= \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2
\end{aligned}$$

En étudiant le comportement de cette variance lorsque le nombre d'arbres grandit indéfiniment, on obtient :

$$\lim_{B \to \infty} \mathrm{Var}\left(\frac{1}{B}\sum_{b=1}^{B} T_b\right) = \rho\sigma^2$$

Conclusion : Peu importe le nombre d'arbres B que l'on ajoute dans la forêt, la variance ne peut jamais descendre en dessous de $\rho\sigma^2$. Il est donc aussi primordial de réduire la corrélation ρ entre les arbres sans trop augmenter leur variance.

Cela peut être réalisé durant le processus de construction des arbres, via le tirage aléatoire des variables à chaque coupure. Plus précisément, avant de choisir la meilleure division à chaque nœud, on sélectionne aléatoirement un sous-ensemble de $m \leq d$ variables parmi les d disponibles.

Remarque: Le paramètre m est un hyperparamètre à ajuster, généralement fixé à $\sqrt{d}$ en classification et $d/3$ en régression dans la littérature.

3 Algorithme

Algorithm 1: Random forest pour la régression et la classification

for $b = 1, \ldots, B$ **do**

1. Tirer un échantillon bootstrap $\mathcal{D}_b$ de taille n à partir de $\mathcal{D}$; 4
2. Construire un arbre de décision T_b sur $\mathcal{D}_b$ en faisant récursivement les étapes suivantes à chaque nœud :
   (a) Tirer aléatoirement m variables parmi les d disponibles
   (b) Choisir la meilleure division parmi ces m variables
   (c) Répéter les étapes 1 et 2 jusqu'à atteindre un critère d'arrêt

Stocker les arbres $T_1, \ldots, T_B$

Pour prédire la valeur de sortie pour une observation x, calculer :

1. $f(x) = \frac{1}{B} \sum_{b=1}^{B} T_b(x)$ pour la régression
2. $f(x) = \arg\max_k \sum_{b=1}^{B} \mathbb{1}_{\{T_b(x)=k\}}$ pour la classification

return $f(x)$

4 Estimations Out-Of-Bag (OOB)

Un échantillon bootstrap $\mathcal{D}_b$ est obtenu en tirant n observations avec remise à partir de l'ensemble de données d'origine $\mathcal{D}$. La probabilité qu'un point n'appartienne pas à l'échantillon bootstrap est $(1 - \frac{1}{n})^n$, qui tend vers $e^{-1} \approx 0.368$ lorsque n devient grand. Ainsi, environ 36,8% des observations ne sont pas incluses dans chaque échantillon bootstrap.

Il est ainsi possible d'évaluer la performance de généralisation de la forêt: pour chaque observation, on calcule sa prédiction en agrégeant uniquement les arbres de la forêt qui ne l'ont pas vue durant leur phase d'entraînement. Cela fournit une estimation non biaisée de l'erreur de généralisation, similaire à une validation croisée, sans nécessiter de jeu de test séparé.

NB: L'erreur OOB n'a pas été implémentée dans ce projet, mais elle est disponible dans la librairie Scikit-learn.

5 Complexité

Les arbres sont indépendants, donc le coût d'entraînement est B fois celui d'un arbre de décision. La complexité temporelle de l'entraînement d'une forêt aléatoire est de l'ordre de $\mathcal{O}(B \times max_depth \times n^2 \times m)$ en utilisant notre implémentation naïve de l'algorithme CART sans tri préalable.

Références

1. Breiman, L. (2001). Random forests. Machine learning, 45(1), 5-32.

2. Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: data mining, inference, and prediction. Springer Science & Business Media.

3. Géron, A. (2019). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media.