Random Forests

O'nel Hounnouvi

1 Modélisation

On dispose d'un jeu de données $\mathcal{D} = (X, y)$ avec $X \in \mathbb{R}^{n \times d}$ (n échantillons, d variables), et $y \in \mathbb{R}^n$ en régression ou $y \in \{1, \dots, K\}^n$ en classification.

Une forêt aléatoire est un ensemble de B arbres de décision randomisés $T_1, \dots, T_B$ (construction des arbres détaillée dans le document Decision Tree), entraînés indépendamment les uns des autres, conditionnellement à $\mathcal{D}$.

La prédiction agrège les sorties des arbres : en régression, on en calcule la moyenne, et en classification, on prend la classe majoritaire parmi les prédictions des arbres.

$$f(x) = \frac{1}{B} \sum_{b=1}^{B} T_b(x) \quad \text{(régression)}, \qquad f(x) = \arg\max_k \sum_{b=1}^{B} \mathbb{1}_{\{T_b(x)=k\}} \quad \text{(classification)}$$

L'un des problèmes majeurs des arbres de décision réside dans leur forte variabilité. Souvent, une légère modification des données peut entraîner une série de divisions de l'arbre très différente, rendant l'interprétation des résultats difficile. La cause principale de cette instabilité tient à la nature hiérarchique du processus : l'impact d'une erreur lors de la première division se propage à toutes les divisions qui en découlent.

2 Objectif : Bagging

L'idée fondamentale du bagging consiste à aggréger plusieurs arbres de décision bruités mais approximativement non biaisés, afin de réduire la variance.

Références

1. Breiman, L. (2001). Random forests. Machine learning, 45(1), 5-32.

2. Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: data mining, inference, and prediction. Springer Science & Business Media.

3. Géron, A. (2019). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media.